Базовые модели. Изменение размерности входных екторов

Лабораторная работа № 5

2 подхода к работе:

1. Загружаем блокнот предыдущей лабораторной работы и переходим к слайду № 7 (можно просмотреть мельком)
2. В новом блокноте загружаем датасет и выполняем быструю загрузку «чистого» набора (см. Слайды 3-6)

Подготовка набора данных

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

Подготовка набора данных

Загрузим очищенную выборку. Можете использовать данные из прошлой лабораторной работы

```
[ ] df = pd.read_csv('/content/train.csv')
    df
```

	PassengerId	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
0	1	0	3	Male	22.0	1	0	7.2500	3
1	2	1	1	female	38.0	1	0	71.2833	1
2	3	1	3	female	26.0	0	0	7.9250	3
3	4	1	1	female	35.0	1	0	53.1000	3

```
df.drop(['PassengerId'],axis=1,inplace=True)
df
```

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
0	0	3	Male	22.0	1	0	7.2500	3
1	1	1	female	38.0	1	0	71.2833	1
2	1	3	female	26.0	0	0	7.9250	3

Подготовка набора данных

Проверим пропуски

```
[ ] df.isnull().sum()
```

```
Survived    0
Pclass      0
Sex         0
Age         0
SibSp       0
Parch       0
Fare        0
Embarked    0
dtype: int64
```

Подготовка набора данных

Выполним замену признака Пол на числовые значения любым способом, например,

```
[ ] sex_scale={'female':1,'male':0,'Male':0,'Female':1}
    df['Sex'].replace(sex_scale,inplace=True)
    df
```

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
0	0	3	0	22.0	1	0	7.2500	3
1	1	1	1	38.0	1	0	71.2833	1
2	1	3	1	26.0	0	0	7.9250	3

Подготовка набора данных

Построим матрицу корреляции

```
[ ] dfc=df.corr().round(2)
    sns.heatmap(data=dfc,annot=True)
```

```
<Axes: >
```

Подготовка набора данных

Выделим целевой признак

```
[ ] Y=df['Survived']
    Y
```

```
0      0
1      1
2      1
3      1
4      0
      ..
884    0
885    1
886    0
887    1
888    0
Name: Survived, Length: 889, dtype: int64
```

Подготовка набора данных

Остальное - X

```
[ ] X=df.drop(['Survived'],axis=1)
    X
```

	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
0	3	0	22.0	1	0	7.2500	3
1	1	1	38.0	1	0	71.2833	1
2	3	1	26.0	0	0	7.9250	3
3	1	1	35.0	1	0	53.1000	3
4	3	0	35.0	0	0	8.0500	3

Подготовка набора данных

Можно загрузить данные для теста

```
[ ] dft = pd.read_csv('/content/test.csv',index_col='PassengerId')
    dft
```

	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
PassengerId											
892	0	3	Kelly, Mr. James	male	34.5	0	0	330911	7.8292	NaN	Q
893	1	3	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1	0	363272	7.0000	NaN	S
894	0	2	Myles, Mr. Thomas Francis	male	62.0	0	0	240276	9.6875	NaN	Q
895	0	3	Wirz, Mr. Albert	male	27.0	0	0	315154	8.6625	NaN	S

Задание

Выполнить обработку тестового набора, как вы делали в прошлой работе

Этот датасет требует обработки!!! Обязательное задание

```
[ ]  #ваш код
```

Подготовка набора данных

Или временно можно для разделить тренеровачный датасет

```
from sklearn.model_selection import train_test_split
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size = 0.1, random_state=5)
```

```
X_train.shape
```

```
(800, 7)
```

Подготовка набора данных

Создадим модель DecisionTree

```
from sklearn.tree import DecisionTreeClassifier
dtf = DecisionTreeClassifier(random_state=0)
dtf.fit(X_train,Y_train)
pred_1=dtf.predict(X_test)
```

Построим матрицу ошибки

```
df1=pd.crosstab(Y_test,pred_1)
df1
```

col_0	0	1
Survived		
0	45	14
1	6	24

Подготовка набора данных

Выполним оценку

```
[ ] from sklearn.metrics import accuracy_score,precision_score,recall_score
    print('accuracy',accuracy_score(Y_test,pred_1))
    print('precision',precision_score(Y_test,pred_1))
    print('recall',recall_score(Y_test,pred_1))
```

```
accuracy 0.7752808988764045
precision 0.631578947368421
recall 0.8
```

Общий отчёт, проанализируйте результат

```
[ ] from sklearn.metrics import classification_report
    print(classification_report(Y_test,pred_1))
```

```
              precision    recall  f1-score   support

           0       0.88      0.76      0.82        59
           1       0.63      0.80      0.71        30

    accuracy                           0.78        89
   macro avg       0.76      0.78      0.76        89
```

Подготовка набора данных

Построим кривые ROC

```
[ ] from sklearn.metrics import RocCurveDisplay
    dtf_disp = RocCurveDisplay.from_estimator(dtf, X_test, Y_test)
    plt.show()
```

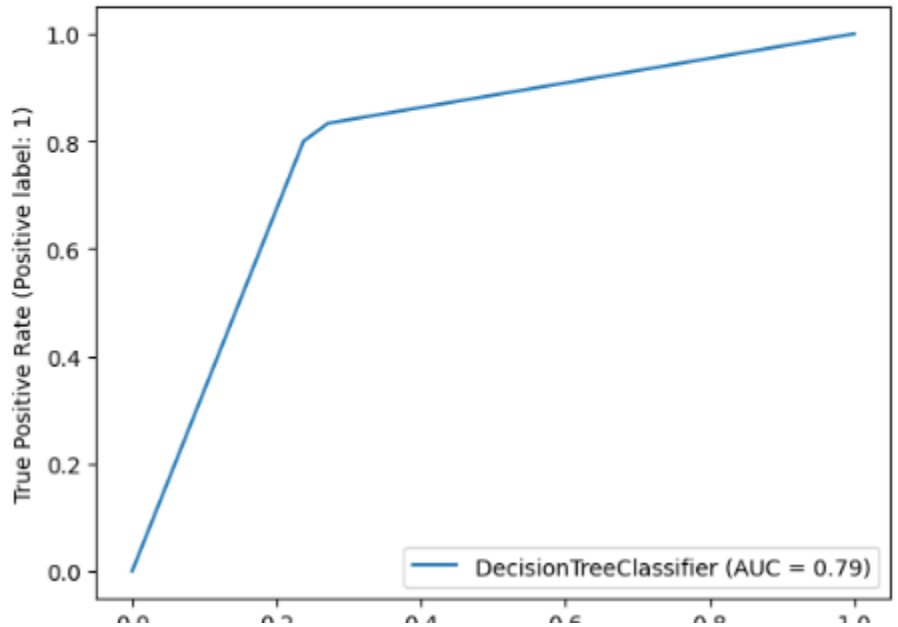

Задание

+ Код + Текст

Постройте другие модели (не менее 5-ти) Разместите графики ROC на одном рисунке

```
[ ]
```

Обучите модели на полном наборе. Для тестирования используйте отдельный набор

```
[ ]  #ваш код
```

Уменьшите количество признаков (см. матрицу корреляции) Постройте модели и проанализируйте результаты

```
[ ]  #ваш код
```

Увеличьте количество признаков Постройте модели и проанализируйте результаты

```
[ ]  #ваш код
```

Задание

- Можете загрузить любой другой датасет для задачи бинарной классификации (например, из kaggle)
- Выполнить анализ и предобработку
- Создать модели и оценить их